面向流式部署的轻量无参考语音质量评估

作者：　　单位：　　通信作者：　　基金：

中图分类号：TN912.3；TP18　文献标志码：A

摘　要：针对通信语音质量监测的计算与状态内存约束，构建单向双层门控循环单元（gated recurrent unit，GRU）与增量注意力池化组成的轻量模型，同时预测平均主观意见分（mean opinion score，MOS）及噪声、音色、不连续性和响度。模型采用训练侧固定增益保留输入电平，以因果谱前端、跨块循环状态和数值稳定的增量池化持续接收语音，独立输出五维评分。在 NISQA 验证集上，模型的原始 Pearson 为 0.7863，高于 PLCMOS 的 0.6950、UTMOSv2 的 0.7332、DNSMOS 的 0.6719 及 SQUIM 的 0.6829；在 FOR 与 TCD-VoIP 中，对 PLCMOS 的训练映射 RMSE 配对差区间跨零，训练侧选择与跨来源评价分离，相关性使用原始预测，误差指标采用冻结的训练校准。模型含前端原生计算量为 13.7139 MMACeq/音频秒，不足官方 NISQA MOS 单头的 1/10、约为 PLCMOS 的 1/170；部署计算量为 12.2767 MMACeq/音频秒，精简流式进程常驻内存为 35.6 MB，16/48 kHz 输入的状态上界为 7.072 kB，10 ms 分块计算中位数和 P99 为 0.53 ms 及 3.35 ms。三种子逐文件预测平均的前端比较显示，仅以训练侧固定增益替代整段峰值归一化，模拟到真实的 MOS MAE 由 0.4502 降至 0.4108，响度 MAE 由 0.7732 降至 0.4642；保留峰值处理并另行提供原始电平统计也降低误差，两条路径支持绝对电平信息可得性的作用，其中固定增益路径适合流式实现。已知网络参数的合成探针显示，丢包线索可观测性随补偿方式变化，学习检测特征在不连续性预测中具有增量。真实通话来源仍呈现较大的泛化误差，误差分解及丢包响应显示线性相关信息和单调性仍有提升空间。

关键词：无参考语音质量评估；轻量模型；流式推理；跨域泛化；丢包可观测性

Lightweight Non-Intrusive Speech Quality Assessment for Streaming Deployment

Authors:　　Affiliations:

Abstract: The estimator uses a unidirectional two-layer gated recurrent unit (GRU) and incremental attention pooling to predict mean opinion score (MOS), noisiness, coloration, discontinuity, and loudness under computation and state-memory constraints. The model retains input levels with a training-fitted fixed gain and continuously processes speech through a causal spectral frontend, cross-block recurrent states, and numerically stable incremental pooling. On NISQA VAL, the model achieves a raw Pearson correlation of 0.7863, exceeding PLCMOS (0.6950), UTMOSv2 (0.7332), DNSMOS (0.6719), and SQUIM (0.6829); its paired TRAIN-mapped RMSE difference intervals against PLCMOS cross zero on FOR and TCD-VoIP; training-side selection remains separate from cross-source evaluation, correlations use raw predictions, and error metrics use frozen training-side calibration. Including the frontend, the native path requires 13.7139 MMACeq per audio second, less than 1/10 of official NISQA MOS and approximately 1/170 of PLCMOS; the deployment path requires 12.2767 MMACeq per audio second, uses 35.6 MB of resident memory in a compact streaming process, retains at most 7.072 kB for 16/48 kHz inputs, and computes 10 ms blocks with median and P99 runtimes of 0.53 and 3.35 ms. The frontend comparison first averages file predictions across three seeds and shows that replacing whole-utterance peak normalization with a training-fitted fixed gain alone reduces simulation-to-real MOS MAE from 0.4502 to 0.4108 and loudness MAE from 0.7732 to 0.4642; supplying raw level statistics alongside peak normalization also reduces error, supporting availability of absolute-level information, while the fixed-gain path permits streaming implementation. Synthetic probes with known network parameters show that packet-loss cue observability varies with concealment method and that learned detection features improve discontinuity prediction. Real-call sources still exhibit substantial generalization error, and error decomposition and packet-loss responses indicate room for improvement in linear correlation and monotonicity.

Key words: non-intrusive speech quality assessment; lightweight model; streaming inference; cross-domain generalization; packet-loss observability

0 引言

编解码、丢包补偿、背景噪声和电平变化以不同方式影响通信语音听感。ITU-T P.800、P.808 和 P.835 规范传统听评、众包听评及信号、噪声和总体质量的分维评价[1–3]。听评成本限制了持续监测，无参考模型因此需要从接收语音估计质量，并满足终端预算。NISQA 提供总体质量及噪声、音色、不连续性、响度五维预测[4]；PLCMOS 面向丢包补偿质量[5]，DNSMOS 面向降噪质量[6–7]，SQUIM 提供感知质量代理[8]。不同训练目标构成互补参照，部署成本则需覆盖重采样、谱前端和推理。

整段峰值归一化改变绝对电平信息，也引入未来输入依赖；质量变化还与缺损比例及连续组织有

关。Gilbert–Elliott 模型和 E-model 从状态转移与传输损伤描述错误聚集[9–11]。盲估计受到自然停顿和补偿算法影响，声学低能量段与真实丢包的关系需要受控检验。

本文有三项贡献：①比较整段峰值归一化、训练侧固定增益与原始电平统计，识别出跨域误差与绝对电平信息可得性的关系，并说明两种补偿路径中只有一种与流式推理相容；②构建轻量流式五维模型，联合跨集误差分解和含前端实际成本呈现部署权衡；③利用已知网络参数探针研究补偿方式对丢包线索可观测性的影响及其不连续性预测增量。

1 相关工作

P.563 提供窄带无参考评价，PESQ 采用参考信号[12–13]；MOSNet 学习合成语音平均主观意见分（mean opinion score，MOS），NISQA 学习通信五维质量[4,14]。UTMOS[15]和 MOS-Bench 关注跨域泛化[16]，FUSE-MOS 研究融合及预测不确定性[17]；发音和说话人任务与通信质量目标不同[18–19]。DNSMOS OVRL/BAK 及 SQUIM PESQ 保持总体、噪声和感知代理身份。

G.107/G.113/G.107.1 的传输损伤估计依赖可确认参数[11,20,21]。本文以梯度提升树、可分离卷积和门控循环单元（gated recurrent unit，GRU）控制容量[22–24]，用 AdamW 及知识蒸馏训练学生[25–26]；轻量增强提供其他预算路线[27–28]。

2 方法

2.1 循环学生与五维监督

图 1 中 GRU 输入为 16 kHz、48 维对数梅尔谱，窗长 20 ms、帧移 10 ms。每折 TRAIN 拟合固定增益及标准化，四项电平统计取处理前波形；首版采用整段峰值归一化。实际带宽按来源记录，升采样不增加信息。

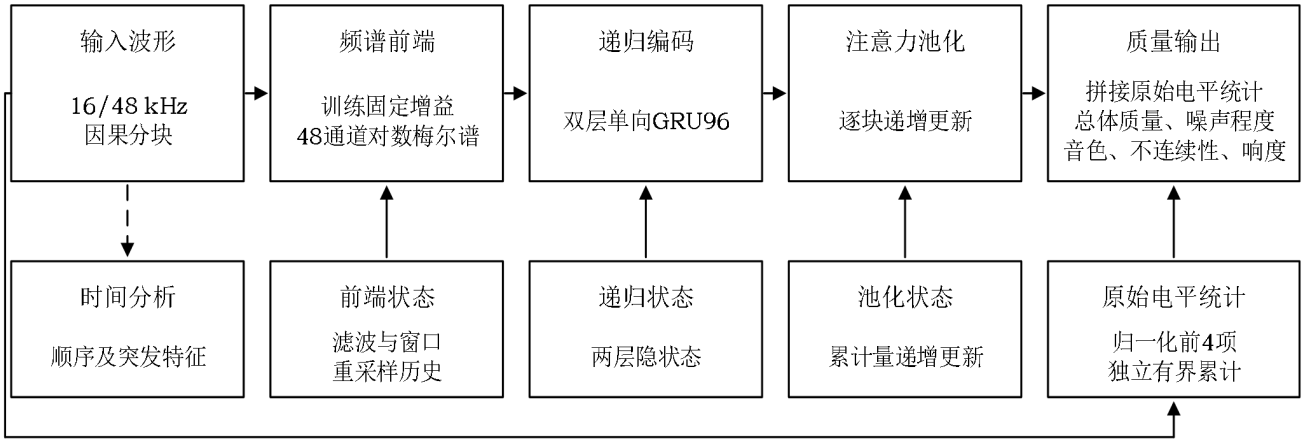


图 1　本文模型的因果流式质量预测框架

Fig. 1　Causal streaming architecture of the proposed quality model

虚线为独立时间分析；原始电平统计在归一化前计算，在池化后、输出头前拼接。

循环输出 h_t 经注意力 a_t 及有效帧掩码池化，输出 MOS、噪声（noisiness，NOI）、音色（coloration，COL）、不连续性（discontinuity，DIS）及响度（loudness，LOUD）。式（1）中 yhat_d/y_d 为预测/标签，MOS 权重 w_d=1，其余 0.5；padding 和缺失标签不计入。

$$L_{\mathrm{sup}} = \sum_{\mathrm{d}} w_{\mathrm{d}} (\hat{y}_{\mathrm{d}} - y_{\mathrm{d}})^2 \quad (1)$$

AdamW 初始学习率 10^{-3}、余弦退火、最多 60 轮、训练内早停 8 轮。首版五种子、容量种子 0/1/2，留出标签不参与早停；含前端乘加运算（multiply–accumulate，MAC）预算≤NISQA 的 1/10。

2.2 固定软目标与模型选择

式（2）以α=0.7 混合真实标签 y 与官方 NISQA 教师 y_teacher 的平方损失 L；部署由学生独立运行，候选使用相同前端。

$$L_{\mathrm{distill}} = \alpha L(\hat{y}, y) + (1-\alpha) L(\hat{y}, y_{\mathrm{teacher}}) \quad (2)$$

最终候选为双层 GRU96、双层 GRU64 和卷积 k5+GRU64，各完成三种子五折及来源留出。主模型以种子 20261011、15 次 CV 最佳轮数中位数拟合全 TRAIN，种子 0 折外预测拟合映射；原值 Pearson 积矩相关与 Spearman 秩相关为主要相关指标。

AISHELL-1 仿真及 THCHS-30 留出源用于受控丢包响应，与质量选模分别报告。

2.3 时间描述符及其顺序分解

时间支路在 16 kHz 峰值归一化波形上用 20/40/80 ms 帧、半帧移，活动判定含 hangover 及≤150 ms 间隙连接；异常序列 b_t 的转移仅在活动段内累计。

式 (3) 中 N 为活动帧数、L_k 为异常游程长度，μ/σ为游程起点间隔的均值/标准差；ρ、r、B 表示异常占比、最长游程比例及间隔突发度。

$$\rho=\frac{\sum_t b_t}{N},\ r=\frac{max_k L_k}{N},\ B=\frac{\sigma-\mu}{\sigma+\mu} \quad (3)$$

N_ij 为相邻状态 i→j 计数，式（4）的 p/q 采用 Jeffreys 伪计数；式（5）派生声学链 BurstR/Ppl，与真实包链的对应由探针检验。

$$p=\frac{N_{01}+0.5}{N_{00}+N_{01}+1},\ q=\frac{N_{10}+0.5}{N_{10}+N_{11}+1} \quad (4)$$

$$\mathrm{BurstR}=\frac{1}{p+q},\ P_{\mathrm{pl}}=\frac{p}{p+q} \quad (5)$$

原 T 有 12 维，新 T 单尺度 19 维，含近零、谱距离及 pYIN 基频跳变统计[29]。

自然/乱序特征相关>0.99 归为近似不变组，其余为顺序组。原 T 打乱通量、能量及平坦度序列，新 T 打乱活动范围内能量及对应分块；保留边际分布，以乱序 TRAIN 重拟合检验顺序贡献。

2.4 增量池化与流式前端

GRU 跨块传递状态；式（6）维护注意力最大值 m、分子 u、分母 z，以新块注意力 a_j、输出 h_j 更新，池化为 u/z，与同设备完整池化比较。

$$\begin{aligned} m' &= max(m, max_j a_j) \\ u' &= e^{m-m'}u+\sum_j e^{a_j-m'}h_j \\ z' &= e^{m-m'}z+\sum_j e^{a_j-m'} \end{aligned} \quad (6)$$

前端只保留下一窗样本及重采样状态。首版分块参照依赖已知整段峰值，本文去除该依赖，测量 10/20/100 ms 块；支持 16/48 kHz，其他采样率需额外状态。

单层 GRU 的主要矩阵乘加量按式（7）计数，I 与 H 分别为输入和隐藏维数，T 为有效帧数。注意力、输出头、STFT、梅尔及重采样另计；非线性运算和 FFT 等价运算估计单独标注，总成本覆盖上述各部分。

$$MAC_{\mathrm{GRU}}=3TH(I+H) \quad (7)$$

3 实验设置

3.1 数据与训练侧选择

误差采用平均绝对误差（mean absolute error，MAE）和均方根误差（root mean square error，RMSE）。表 1 列样本与分组：TRAIN/VAL 条件逐文件唯一，TEST 另有条件聚合；LIVETALK 参考字段缺失，按文件回退。

表 1 数据与分组

Table 1. Data and grouping

数据子集	文件	参考分组	条件	分组依据
TRAIN_SIM	10000	10000	10000	元数据源参考/源语句
TRAIN_LIVE	1020	495	1020	元数据源参考/源语句
VAL_SIM	2500	2500	2500	元数据源参考/源语句
VAL_LIVE	200	102	200	元数据源参考/源语句
TEST_FOR	240	240	60	元数据源参考/源语句
TEST_P501	240	4	60	元数据源参考/源语句
TEST_LIVETALK	232	232	58	文件回退，非真实源参考

TRAIN/VAL 条件逐文件唯一；LIVETALK 的参考组数是回退文件数。

五折按源参考或源语句分组，同一参考的降质版本保持在同折。四 SIM 来源留出分别留出 AusTalk、DNS、TSP 和 UKIRE，训练保留 LIVE；DNS 来源留出仍可见 DNS 的 LIVE 源语句。SIM→LIVE 仅用模拟域训练、真实域评价。结构选择采用 0.4×CV 等域 MOS MAE+0.4×四 SIM 来源留出 MAE+0.2×SIM→LIVE MAE，分差小于 0.005 选含前端 MAC 较低者；CV 与来源留出改善均小于 0.01 时保留首版。三个候选在 TRAIN 选定后各评价一次 VAL，冻结主模型各评价一次测试集，成绩不改变选择。

TCD-VoIP 含 384 条和 96 个失真条件，其中 chop 类 96 条、24 条件。其 TSP2002 四说话人录音池与 NISQA 部分 TRAIN 具有来源池及说话人重叠，提供跨条件、独立听评评价。官方 NISQA 权重开发涉及公开 VAL 的早停与选择，教师及蒸馏学生的 VAL 属于开发曝光范围。历史 schema 核对曾输出部分测试评分文本而未读对应音频；早期首版及其他模型随后实际完成测试评价。本轮选择仅用 TRAIN，VAL/测试按已有曝光后的冻结模型作描述性评价；冻结后的 GRU96 前端四臂分析使用 TRAIN，评价后收到的聚合与表述规则不参与选模。

3.2 评价与不确定性

MAE 和 RMSE 衡量误差，Pearson 与 Spearman 使用原始预测。域内分别计算后等权平均，三个 NISQA 测试集宏平均再按数据集等权。条件层先平均同条件标签与预测。学生的三阶校准用 TRAIN 折外预测拟合，PLCMOS 等比较法用既定 TRAIN 预测拟合，非单调三阶退回一阶；官方 NISQA 保持原值。逐目标集线性映射只作目标标签尺度校正的次要分析，部署使用固定 TRAIN 映射[30]。

TRAIN/VAL 按参考组、TEST 按条件组作 2000 次同步配对 bootstrap，报告 95%百分位区间。每个数据集×文件/条件层面×MOS 指标对首版、PLCMOS、NISQA 三比较者共同作 Holm 校正，合计 24 族 72 项。前端四臂先平均种子 0/1/2 逐文件预测，再计算域/来源等权指标并作参考组分层 bootstrap；该聚合规则在原拟合结果后收到，在聚合前固定，结果后 B−D 比较仅用于机制解释。20 次乱序重拟合的经验概率为(k+1)/(n+1)，k 为不劣于自然值的乱序次数，n=20。

3.3 对比模型与测量平台

首版（无蒸馏）指仅真实标签监督的 8070 参数 GRU；首版指相同容量的蒸馏 GRU；本文模型指冻结双层 GRU96。NISQA 采用作者官方五维权重，其 MOS 单头仅末层偏置与五维 MOS 头相差 0.0559，单头只作成本实现参照。PLCMOS 使用官方权重及作者重采样和 15 次调用；DNSMOS 沿用官方 16 kHz 处理及 OVRL 输出；SQUIM 采用官方 16 kHz 输入及 PESQ 代理；P.563 在 8 kHz 输入上报告有效样本。UTMOSv2 沿用作者五折权重、每折五次随机裁剪，提供 VAL 原值指标，无 TRAIN 映射。

质量训练使用 RTX4090，成本平台为 i7-13700KF。S1 为不绑核的库默认线程，S2/S3 分别为单性能核/单能效核单线程；固定 600 条 VAL、热缓存、20 文件预热和五个独立进程重复，分离读取、预处理、前端与推理，报告常驻内存（resident set size，RSS）及实时因子（real-time factor，RTF，处理耗时/音频时长）。基础应用背景受控，核心温度不可用；16 设置中 8 项通过稳定性标准，失败项保留实测标记。完整 2700 条 VAL 核对代表性。流式在 200 个随机 TRAIN 文件上比较同设备完整与分块输出，最大绝对差门限 10^{-5}；CPU/CUDA 差异另记。动态 INT8 在 TRAIN 折外检验，局部线性量化与 GRU 及线性量化分别报告。

4 结果与分析

4.1 电平信息、容量与跨集精度

绝对电平可以由训练侧固定增益保留，或由峰值归一化前的原始电平统计补入；第二条路径保留整段峰值依赖。早期约 8 千参数的前端选择中，固定增益与四统计组合将 SIM→LIVE MOS MAE 由 0.5725 降至 0.4507，LOUD 由 0.9087 降至 0.5660，按 3.1 综合分确定前端。表 2 列出五个代表容量档。可比 GRU 系列的 CV 与来源留出误差随容量降低，双层 64 单元之后 SIM→LIVE 点值接近饱和；全部架构并不呈单调规律。双层 GRU96 的 CV 与来源留出 MOS MAE 为 0.4176 和 0.5540，相对首版改善 0.0729 和 0.0975，通过 0.01 止损规则。

表 2 代表结构与容量的 MOS 训练结果

Table 2. MOS training results for representative architectures and capacities

结构	参数	CV MAE	四来源留出 MAE	模拟→真实 MAE
单层 GRU 32	8090	0.4828 ± 0.0118	0.6427 ± 0.0111	0.4507 ± 0.0124
单层 GRU 64	22298	0.4555 ± 0.0159	0.5892 ± 0.0114	0.4522 ± 0.0334
双层 GRU 64	47258	0.4232 ± 0.0042	0.5635 ± 0.0039	0.4509 ± 0.0260
双层 GRU 96 *	98522	0.4176 ± 0.0003	0.5540 ± 0.0108	0.4447 ± 0.0162
卷积 k5+GRU 64	33338	0.4441 ± 0.0062	0.5769 ± 0.0073	0.4741 ± 0.0372

三个训练种子指标均值±SD；相同 16 kHz、48 梅尔前端，真实标签/官方五维教师权重 0.7/0.3。按 3.1 综合分及成本规则选择 * 结构。SD 表示初始化变化；本表保持原容量选择口径，与表 3 先平均预测的后见口径区分。

冻结后在 GRU96 上比较四配置：A 为峰值归一化且无四统计，B 为固定增益加四统计，C 为固定增益且无四统计，D 为峰值归一化加原始四统计。表 3 给出 A/B。SIM→LIVE MOS 和 LOUD 的 A−B 改善分别为 +0.0337 [+0.0184, +0.0499]、+0.2823 [+0.2592, +0.3054]；CV MOS 区间跨零，四来源留出 MOS 区间为正。在约 8 千与 9.9 万参数两种容量下，以固定增益加运行电平统计替代整段峰值归一化均显著降低模拟到真实迁移误差，结论一致。

表 3 双层 GRU96 前端 A/B 的 MAE 与相关性

Table 3. MAE and correlation in the two-layer GRU96 frontend A/B comparison

训练设计	维度	MAE A→B	A−B 下降量 [95%CI]	Pearson A→B	B−A 增量 [95%CI]
等域 CV	MOS	0.4038→0.3981	+0.0057 [-0.0005, +0.0122]	0.8110→0.8129	+0.0020 [-0.0050, +0.0093]
等域 CV	LOUD	0.4316→0.3798	+0.0519 [+0.0442, +0.0598]	0.7138→0.7728	+0.0590 [+0.0473, +0.0709]
四 SIM 来源留出	MOS	0.5523→0.5254	+0.0270 [+0.0183, +0.0355]	0.7905→0.8027	+0.0122 [+0.0044, +0.0198]
四 SIM 来源留出	LOUD	0.4682→0.4139	+0.0543 [+0.0471, +0.0620]	0.7207→0.7838	+0.0631 [+0.0493, +0.0785]
SIM→LIVE	MOS	0.4502→0.4165	+0.0337 [+0.0184, +0.0499]	0.6521→0.6820	+0.0299 [+0.0075, +0.0513]
SIM→LIVE	LOUD	0.7732→0.4909	+0.2823 [+0.2592, +0.3054]	0.4941→0.6621	+0.1681 [+0.1393, +0.1966]

A：整段峰值归一化、无原始电平四统计；B：训练侧固定增益、原始电平四统计。先平均三个种子的逐文件预测，再计算指标；参考组分层同步 bootstrap 2000 次。MAE 下降量和 Pearson 增量均以正值为改善；SIM→LIVE MOS/LOUD 用于表述判断。聚合及表述规则在原拟合结果后收到、聚合前固定；这项 TRAIN 稳健性分析沿用已冻结模型。

仅固定增益 C−A 在 SIM→LIVE 的 MOS 和 LOUD MAE 差为-0.0394 [-0.0572, -0.0223]、-0.3090 [-0.3335, -0.2853]；保留峰值的 D−A MOS MAE 差为 -0.0381 [-0.0473, -0.0291]、LOUD 为-0.2081 [-0.2233, -0.1925]，也降低两维误差，支持绝对电平信息保留的解释。固定增益下 B−C 的 MOS 区间在三设计均跨零，SIM→LIVE LOUD MAE 差为 +0.0267 [+0.0197, +0.0334]，DIS 为-0.0281 [-0.0387, -0.0175]、Pearson 增量+0.0918 [+0.0638, +0.1204]，呈现维度权衡。C 的 SIM→LIVE MOS 点值最低，B 并非最优；B−D 差+0.0044 [-0.0096, +0.0181]跨零。B 来自先前小容量综合分选择，C/D 不在当时菜单，后见分析沿用冻结模型；D 的整段峰值路径无法直接因果流式运行。

独立 48 kHz 高频屏蔽诊断中，屏蔽使 CV MOS MAE 增大 0.1198，SIM→LIVE 原始减屏蔽的 MAE 差为+0.0052 [-0.0015, +0.0121]、区间跨零，带宽信息收益因域而异。

本文模型 VAL 原始 Pearson 为 0.7863，训练映射 RMSE 为 0.5510；表 4 及图 2 比较各来源精度。FOR 与 TCD 对 PLCMOS 的训练映射 RMSE 差分别为 +0.0085 [-0.0791, +0.1004]、+0.0276 [-0.0553, +0.1098]，均跨零；FOR Pearson 差-0.0695 [-0.1698, -0.0035]虽不跨零，Holm 为 0.2069。P501 对 PLCMOS 的 Pearson 差 -0.1166 [-0.2210, -0.0366]，Holm 为 0.0330，保留显著劣势。

表 4 各方法在 VAL 及跨集评价中的 MOS 精度

Table 4. MOS accuracy on VAL and cross-dataset evaluations

方法	VAL r	VAL RMSE	FOR r	FOR RMSE	P501 r	P501 RMSE	LIVE r	LIVE RMSE	TCD r	TCD RMSE
G0 HGB	0.6339	0.6974	0.4335	0.8785	0.4920	1.0516	0.2323	1.1721	—	—
G0+新 T	0.6460	0.6827	0.4086	0.8990	0.5526	1.0059	0.3763	1.0461	—	—
首版（无蒸馏）	0.7267	0.6216	0.6205	0.7935	0.7334	0.9608	0.6239	0.8321	—	—
首版	0.7362	0.6123	0.6440	0.7525	0.7601	0.9070	0.6026	0.8378	0.6963	0.7162
NISQA 五维	0.8614	0.4526	0.9053	0.3943	0.9066	0.5647	0.8337	0.5749	0.8420	0.7292
DNSMOS OVRL	0.6719	0.6875	0.5271	0.9126	0.6771	0.9729	0.6093	0.8853	—	—
PLCMOS	0.6950	0.6173	0.7772	0.6235	0.8751	0.6852	0.7465	0.7001	0.7245	0.7560
SQUIM PESQ 代理	0.6829	0.6462	0.7090	0.6931	0.8395	0.7417	0.6153	0.8986	—	—
P.563	0.4428	0.8211	0.4312	0.9777	0.6970	0.9875	0.5427	0.9153	—	—
UTMOSv2	0.7332	0.8119[b]	—	—	—	—	—	—	—	—
本文模型	0.7863	0.5510	0.7077	0.6320	0.7585	0.8271	0.4969	0.9464	0.7273	0.7836

r 为逐文件原始 Pearson；RMSE 采用既定 TRAIN 映射，官方 NISQA 保持原值。[b] UTMOSv2 未拟合 TRAIN 映射，列原值 RMSE。—表示该评价范围无预测；P.563 使用实际有效样本。DNSMOS OVRL 和 SQUIM PESQ 为不同目标的对比输出。

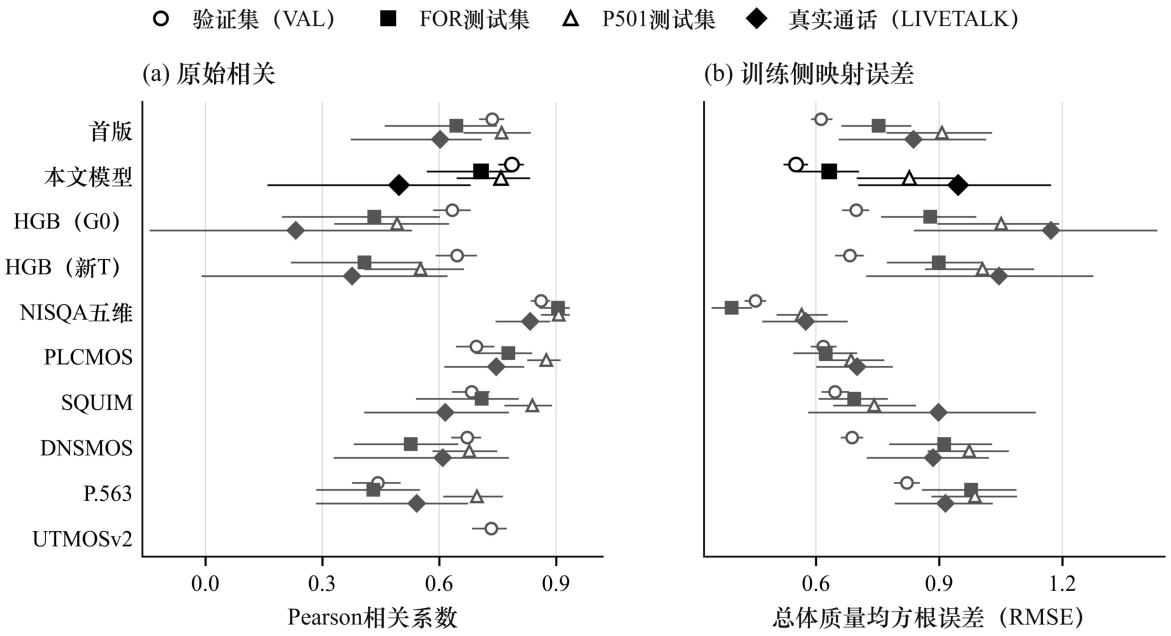


图 2　不同方法的质量预测性能

Fig. 2　Quality prediction performance of different methods

线段为 95%区间；NISQA 五维 RMSE 保留原值。UTMOSv2 无 TRAIN 映射，仅在(a)展示 VAL 原始相关。

FOR 训练映射 RMSE 由首版 0.7525 降至 0.6320，P501 由 0.9070 降至 0.8271，LIVETALK 由 0.8378 增至 0.9464。三集等权 RMSE 为 0.8018，原始 Pearson 为 0.6543；TCD 对应 0.7836、0.7273。表 5 限定 MOS 文件层，条件层使用同一分组协议。

表 5 本文模型对三个比较者的 MOS 文件层配对结果

Table 5. File-level paired MOS comparisons against three comparators

评价集	比较法	Pearson 差 [95%区间]	Holm p	RMSE 差 [95%区间]	Holm p
FOR	首版	+0.0637 [-0.0422, +0.1680]	0.2294	-0.1205 [-0.2023, -0.0325]	0.0180
FOR	PLCMOS	-0.0695 [-0.1698, -0.0035]	0.2069	+0.0085 [-0.0791, +0.1004]	0.8471
FOR	NISQA5D	-0.1976 [-0.3037, -0.1271]	0.0030	+0.2377 [+0.1630, +0.3093]	0.0015
P501	首版	-0.0016 [-0.0652, +0.0544]	0.9570	-0.0799 [-0.1759, +0.0113]	0.0890
P501	PLCMOS	-0.1166 [-0.2210, -0.0366]	0.0330	+0.1420 [-0.0019, +0.2741]	0.0890
P501	NISQA5D	-0.1481 [-0.2452, -0.0757]	0.0090	+0.2624 [+0.1368, +0.3850]	0.0015
LIVETALK	首版	-0.1058 [-0.4023, +0.1101]	0.4278	+0.1086 [-0.1344, +0.3953]	0.5182
LIVETALK	PLCMOS	-0.2497 [-0.5355, -0.0802]	0.0900	+0.2463 [+0.0199, +0.4228]	0.0390
LIVETALK	NISQA5D	-0.3369 [-0.6140, -0.1914]	0.0345	+0.3715 [+0.1991, +0.5118]	0.0015
TCD	首版	+0.0310 [-0.0187, +0.0786]	0.4388	+0.0674 [-0.0091, +0.1381]	0.2099
TCD	PLCMOS	+0.0028 [-0.0643, +0.0662]	0.9470	+0.0276 [-0.0553, +0.1098]	0.5202
TCD	NISQA5D	-0.1147 [-0.1781, -0.0632]	0.0045	+0.0544 [-0.0286, +0.1515]	0.4258

差值=本文模型−比较法；Pearson 取原值，RMSE 使用固定 TRAIN 映射，官方 NISQA 保持原值。每个评价集/层面/指标的三个比较共同 Holm；2000 次条件组同步 bootstrap。

图 3 用原值 MOS 预测分解 MSE：均值偏移 $(\mu_p-\mu_y)^2$、相关调整尺度失配 $(\sigma_p-r\sigma_y)^2$ 与线性相关残差 $(1-r^2)\sigma_y^2$。VAL 按 SIM/LIVE 等权的总 MSE 为 0.3114，三分量为 0.0052、0.0049 及 0.3014；残差反映当前预测与标签的线性相关缺口，并非纯排序误差。LIVETALK 相关残差为 0.7908，与 SIM→LIVE 容量收益饱和共同提示真实来源差距。UTMOSv2

的图 2 RMSE 点因无 TRAIN 映射省略，表 4 另列其原值 RMSE。

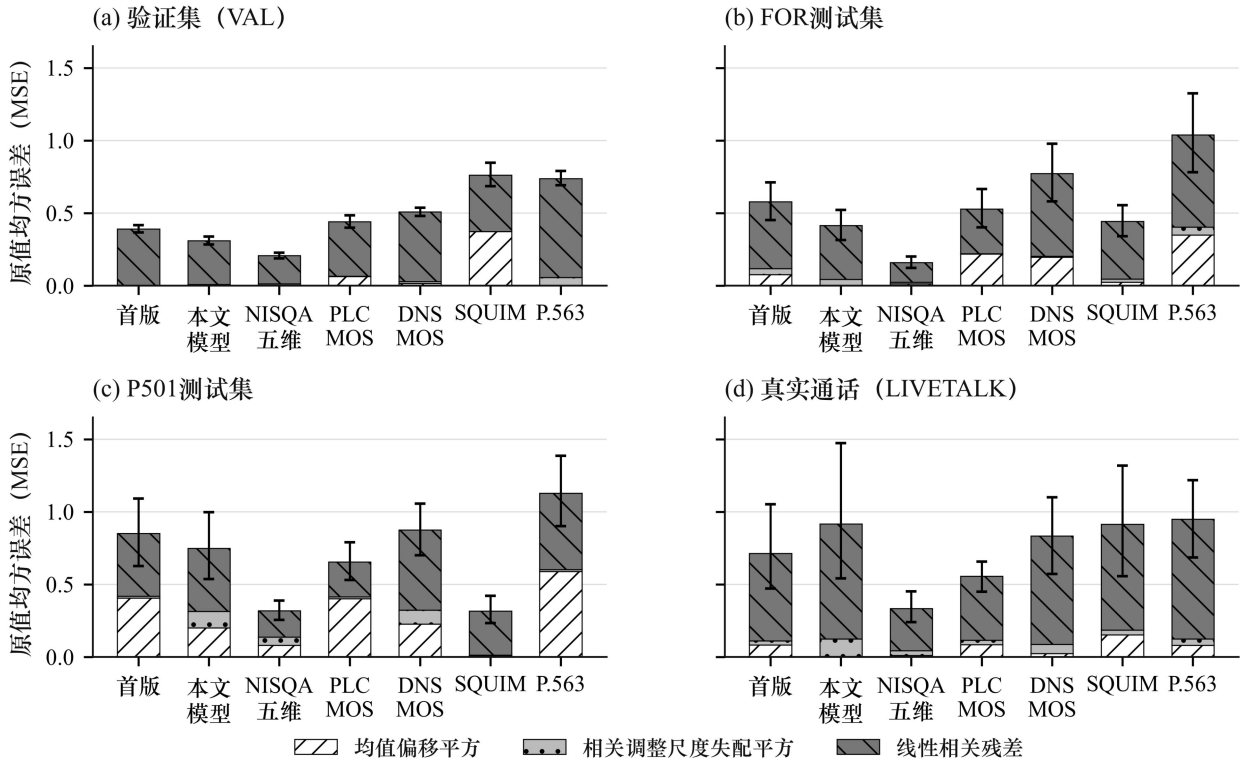


图 3　七种方法的原值总体质量均方误差分解

Fig. 3　Raw overall-quality MSE decomposition for seven methods

各数据集分别计算两域等权分量。误差线为总 MSE 的 95%区间：VAL 按参考组、TEST 按条件组重抽样。

4.2 时间顺序与检测特征增量

原 T 的 20 次乱序重拟合均劣于自然值(经验概率 0.0476)。原 T+新 T 等域 MOS MAE 为 0.5076，对原 T 下降 +0.0167 [+0.0120, +0.0215]；按 source/codec/工作模式/FER 的 0.05 分箱的 247 格、2123 文件调和加权，随机丢包收益更集中。44 维=14 维 G0+12 维原 T+18 维新 T，45 维仅增加相邻有声帧>4 半音的 pYIN 跳变率；历史种子 20261011。检测比较用 seed0/1/2 同容量 HGB，44 维加入 8 维成为 52 维，同参考抽样并平均三种子绝对误差。DIS 等域 MAE 下降+0.0197 [+0.0144, +0.0249]，两域均为正(表6)；MOS 等域下降+0.0025 [-0.0007, +0.0057] 跨零，SIM 改善、LIVE 下降量-0.0083 [-0.0138, -0.0031] 为负。可定义覆盖 SIM/LIVE 为 99.3000%/99.0200%；移除与缺失处理仍保留 LIVE 负增量，固定置信加权缩至-0.0037 [-0.0080, +0.0005]、跨零。

表 6 学习检测特征对 MOS 和 DIS 的增量

Table 6. MOS and DIS increments from learned detection features

维度	域	MAE 前→后	下降量	95%区间
MOS	两域等权	0.5076→0.5050	+0.0025	[-0.0007, +0.0057]
MOS	模拟域	0.6054→0.5920	+0.0134	[+0.0101, +0.0167]
MOS	真实域	0.4098→0.4181	-0.0083	[-0.0138, -0.0031]
DIS	两域等权	0.5679→0.5483	+0.0197	[+0.0144, +0.0249]
DIS	模拟域	0.6554→0.6325	+0.0229	[+0.0188, +0.0268]
DIS	真实域	0.4805→0.4641	+0.0164	[+0.0066, +0.0264]

44 维基础组合加入 8 维检测特征，总 52 维。同容量 HGB、三个训练种子逐文件绝对误差平均；参考组配对 bootstrap 2000 次。下降量为正表示 MAE 降低。

4.3 丢包补偿与可观测性

表 7 展示补偿方式对线索的影响。20 ms 对齐 DSP 在零填充中利用明确缺损，在原生 Opus 中帧

F1 为 0.0321；突发度相关 0.6266 仅对应 950/8000 可定义预测。固定 CNN 在两来源共 20,000 条仿真中，零填充 log BurstR 的 Spearman 由 AISHELL 的 0.8379 降至 THCHS 的 0.6786，联合分母 2828/4181 与 2784/4103；后者低于预定 0.7 线。独立因果波形 CNN-GRU 在原生 Opus 的帧 F1 为 0.5003 与 0.2872，THCHS 低于 0.3 线；阈值由 TRAIN、结构由 DEV 确定。

表 7 补偿线索可观测性与两来源留出表现

Table 7. Concealment-cue observability and two-source held-out performance

来源/探针	补偿	旧 80ms ρ [CI]	DSP 帧 F1	CNN 帧 F1	Ppl MAE	BurstR ρ	联合 n/全部 n
无噪声探针	G.711／零填充	-0.0278 [-0.0447,-0.0104]	1.0000	—	0.0000	1.0000	8000/8000
无噪声探针	Opus／原生 PLC	0.0363 [0.0200,0.0531]	0.0321	—	0.0901	0.6266	950/8000
无噪声探针	Opus／零填充	0.0264 [0.0089,0.0447]	0.9997	—	0.0000	1.0000	8000/8000
无噪声探针	PCM／零填充	-0.0519 [-0.0706,-0.0334]	1.0000	—	0.0000	1.0000	8000/8000
AISHELL 留出	零填充	—	0.2198	0.8085	0.0351	0.8379	2828/4181
AISHELL 留出	重复	—	0.0032	0.7280	0.0456	0.7837	2777/4154
AISHELL 留出	Opus 原生	—	0.0052	0.4822	0.0970	0.3855	569/861
AISHELL 留出	G.711 补偿	—	0.1384	0.5549	0.0636	0.6779	513/804
THCHS 留出	零填充	—	0.2074	0.4476	0.2294	0.6786	2784/4103
THCHS 留出	重复	—	0.0043	0.4262	0.2244	0.6285	2931/4208
THCHS 留出	Opus 原生	—	0.0111	0.2874	0.3558	0.2953	594/889
THCHS 留出	G.711 补偿	—	0.1065	0.3454	0.2736	0.3158	575/800

无噪声探针行的 Ppl 和ρ来自 20 ms 对齐 DSP；来源留出行来自固定 CNN，DSP 列为零检测对照。ρ在联合可定义子集内计算，分母同时给出；20,000 条留出仿真按来源及补偿分层。旧 80 ms 声学链与真实包链的响应区分报告。

100 参考、29 说话人的七条件中，五点丢包曲线四相邻差均≤0 的完整非增比例为 0.0400–0.2525，各条件低于 NISQA 五维及 PLCMOS。10%丢包率、同参考同丢包数的 BurstR 8−1 响应采用说话人簇 bootstrap 2000 次；五固定模型多数预测突发 MOS 较高，方向随补偿变化。E-model 仅匹配 100 条 G.711 20 ms、Repeat1/silence、目标 BurstR 4/Ppl 1%的单网络条件，公式用 BurstR=1，差异来自时长/丢包数舍入；其余 13900 条缺少共同系数。

4.4 计算成本与流式运行

表 8 与图 4 联合精度和成本。本文模型含 98522 参数，原生与部署路径为 13.7139、12.2767 MMACeq/音频秒；官方 NISQA MOS 为 146.0338，PLCMOS 为 2374.40。S2 的首版、本文模型原生/部署与 NISQA MOS 四项测量通过标准，NISQA MOS/部署耗时比为 2.23，漂移扰动敏感性范围 2.16–2.29；范围并非置信区间。S3 部署 RTF 为 0.012003 且通过标准，NISQA 与 PLCMOS 在允许复测后仍未通过、保留†；其 IQR/中位数及最大校准漂移分别为 1.005950%/5.753122%和 2.093258%/6.070037%，阈值为离散度 5%、校准漂移 3%。PLCMOS 实测耗时约慢一个数量级。MAC 比约 12 而 S2 时间比约 2，GRU 逐帧小矩阵、前端占比和算子并行造成不同缩放；S1 默认多线程部署 RTF 0.010000 高于 S2 0.003990，符合线程调度开销。DNSMOS 按作者 9.01 s 短音重复、1 s 离散滑窗并计固定 STFT 卷积，其旧 TRAIN200 时长加权估计与本次 VAL 代表长度口径不同。

表 8 参数、完整运算与整句及流式成本

Table 8. Parameters, full operation estimates, and utterance/streaming costs

模型/路径	参数	MMACeq/秒	S2 RTF	S3 RTF	10ms P99/ms	流式 RSS/MB	状态上界/B
首版	8070	3.0184	0.001866	0.005689	—	—	—
本文模型 原生	98522	13.7139	0.004632	0.013298†	—	—	—
本文模型 整句 F32	98522	12.2767	0.003990	0.012003	3.3505	35.5758	7072
GRU64 整句 F32	47258	7.2127	—	0.011045†	2.4326	35.2133	6560

模型/路径	参数	MMACeq/秒	S2 RTF	S3 RTF	10ms P99/ms	流式 RSS/MB	状态上界/B
官方 NISQA MOS	218402	146.0338	0.008884	0.021922†	—	—	—
PLCMOS	299265	2374.40	—	0.117650†	—	—	—
官方 NISQA 五维	252458	146.8597	—	—	—	—	—
DNSMOS	184032	17954.8954	—	—	—	—	—
SQUIM	7387658	9378.4598	—	—	—	—	—
P.563	—	—	—	—	—	—	—

S2 为单性能核，S3 为单能效核；固定 600 条 VAL、五轮热缓存端到端中位数。†表示复测后仍未通过稳定性标准。10 ms P99 和 RSS 来自独立精简流式内核，状态上界覆盖 16/48 kHz；其他采样率需额外重采样状态。NISQA MOS 单头用于成本，NISQA 五维用于质量。DNSMOS 按 VAL 代表长度、9.01 s 短音重复和 1 s 离散窗口估计，含固定 STFT 卷积；与旧 TRAIN200 时长加权口径不同。 †实际失败值：NISQA_MOS S3 的 IQR/中位数 1.005950%、最大校准漂移 5.753122%；PLCMOS S3 的 IQR/中位数 2.093258%、最大校准漂移 6.070037%；离散度阈值 5%、校准漂移阈值 3%，这些测量量及敏感性范围均非置信区间。

整句 S3 峰值 RSS 为 285.9663 MB，包含框架和音频缓冲；独立精简流式进程 10 ms 块 RSS 为 35.6 MB，中位与 P99 耗时 0.53、3.35 ms。10/20/100 ms 块P99均低于块周期，20 ms块算法时延20.6250 ms、未来前瞻 0。支持 16/48 kHz 的本文模型与 GRU64 状态上界为 7072、6560 B，其他采样率需额外重采样状态。部署与同设备冻结输出最大差 6.91e-06；动态 INT8 总体指标变化较小而个别预测误差较大，独立流式最大差 0.0132 超出 10^{-5}门限，采用浮点部署。完整 VAL 代表性核对相对差 3.94%/1.02%低于 5%；这些桌面测量尚待嵌入式硬件验证。

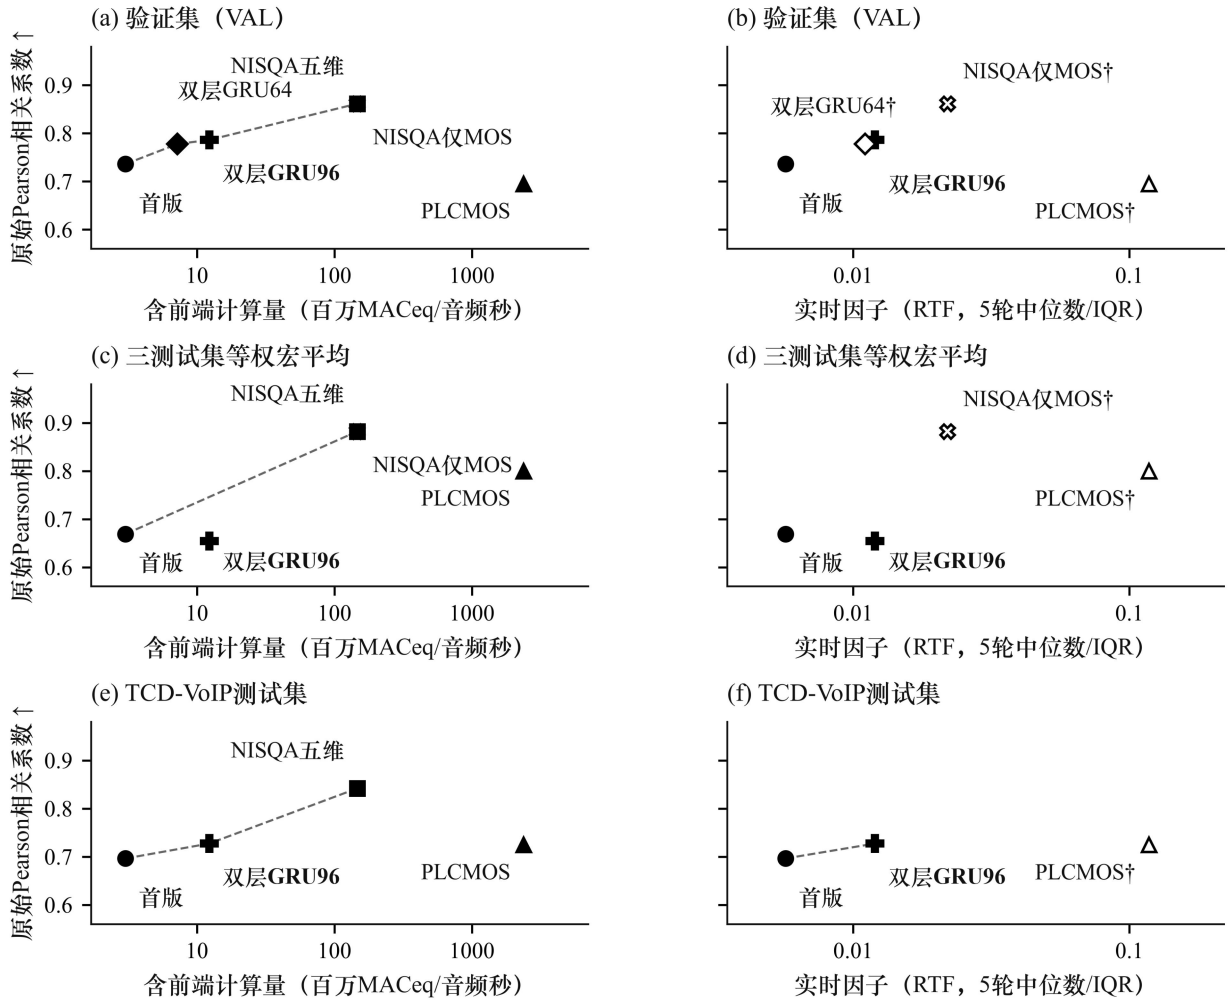


图 4　质量预测与部署成本的权衡

Fig. 4　Trade-off between quality prediction and deployment cost

质量：GPU 推理；成本：Windows CPU。实心为已验收，空心†为未验收，横线为 RTF 四分位距。GRU64 仅完成 VAL。

5 结论

固定增益和原始电平统计提供两条补偿绝对电平信息的路径，在两种容量中组合前端降低模拟到真实误差，固定增益路径适合因果流式实现。冻结双层 GRU96 以有限含前端运算和状态内存提供五维评估，跨来源精度与成本共同界定部署权衡。已知参数探针表明补偿方式改变丢包线索可观测性，学习检测在 DIS 有稳定增量，在 MOS 呈现域间差异。

真实通话来源的泛化、丢包响应单调性和盲突发度跨源误差仍有限；教师与历史测试曝光、TCD 录音池重叠、仿真 16 kHz 原生带宽及 E-model 参数范围限定了评价解释。现有成本来自桌面平台，支持 16/48 kHz 输入。后续研究重点是缩小合成与无标签真实语音的分布差距。

数据与代码可用性：本文使用 NISQA、TCD-VoIP、AISHELL-1 和 THCHS-30 的公开研究数据。版本化评价协议、预测、完整结果表、成本分解和复现代码的存档地址为已建立的公开 GitHub 仓库 https://github.com/chenyikai1207/nisqa-streaming-quality，本稿关联版本标签为 nisqa-paper1-ecice-v32-20261014；原始音频按各数据集许可从作者来源获取。

参考文献

[1] ITU-T. Methods for subjective determination of transmission quality: ITU-T P.800 (08/1996)[S]. Geneva: International Telecommunication Union, 1996.

[2] ITU-T. Subjective evaluation of speech quality with a crowdsourcing approach: ITU-T P.808 (06/2021)[S]. Geneva: International Telecommunication Union, 2021.

[3] ITU-T. Subjective test methodology for evaluating speech communication systems and terminals providing noise suppression functionality: ITU-T P.835 (07/2026)[S]. Geneva: International Telecommunication Union, 2026.

[4] MITTAG G, NADERI B, CHEHADI A, et al. NISQA: A Deep CNN-Self-Attention Model for Multidimensional Speech Quality Prediction with Crowdsourced Datasets[C]//Interspeech 2021. [S. l.]: ISCA, 2021: 2127-2131. DOI: 10.21437/interspeech.2021-299.

[5] DIENER L, PURIN M, SOOTLA S, et al. PLCMOS – A Data-driven Non-intrusive Metric for The Evaluation of Packet Loss Concealment Algorithms[C]//INTERSPEECH 2023. [S. l.]: ISCA, 2023: 2533-2537. DOI: 10.21437/interspeech.2023-1532.

[6] REDDY C K A, GOPAL V, CUTLER R. DNSMOS: A non-intrusive perceptual objective speech quality metric to evaluate noise suppressors[C]//ICASSP 2021. [S. l.]: IEEE, 2021: 6493-6497. DOI: 10.1109/icassp39728.2021.9414878.

[7] REDDY CKA, GOPAL V, CUTLER R. Dnsmos P.835: A Non-Intrusive Perceptual Objective Speech Quality Metric to Evaluate Noise Suppressors[C]//ICASSP 2022 - 2022 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). [S. l.]: IEEE, 2022: 886-890. DOI: 10.1109/icassp43922.2022.9746108.

[8] KUMAR A, TAN K, NI Z, et al. TorchAudio-SQUIM: Reference-less speech quality and intelligibility measures in TorchAudio[EB/OL]. (2023-04-03)[2026-10-11]. https://arxiv.org/abs/2304.01448.

[9] GILBERT E N. Capacity of a burst-noise channel[J]. Bell System Technical Journal, 1960, 39(5): 1253-1265. DOI: 10.1002/j.1538-7305.1960.tb03959.x.

[10] ELLIOTT E O. Estimates of error rates for codes on burst-noise channels[J]. Bell System Technical Journal, 1963, 42(5): 1977-1997. DOI: 10.1002/j.1538-7305.1963.tb00955.x.

[11] ITU-T. The E-model: A computational model for use in transmission planning: ITU-T G.107 (02/2014)[S]. Geneva: International Telecommunication Union, 2014.

[12] ITU-T. Single-ended method for objective speech quality assessment in narrow-band telephony applications: ITU-T P.563 (05/2004)[S]. Geneva: International Telecommunication Union, 2004.

[13] ITU-T. Perceptual evaluation of speech quality (PESQ): An objective method for end-to-end speech quality assessment of narrow-band telephone networks and speech codecs: ITU-T P.862 (02/2001)[S]. Geneva: International Telecommunication Union, 2001.

[14] LO CC, FU SW, HUANG WC, et al. MOSNet: Deep Learning-Based Objective Assessment for Voice Conversion[C]//Interspeech 2019. [S. l.]: ISCA, 2019: 1541-1545. DOI: 10.21437/interspeech.2019-2003.

[15] SAEKI T, XIN D, NAKATA W, et al. UTMOS: UTokyo-SaruLab system for VoiceMOS Challenge 2022[C]//Interspeech 2022. [S. l.]: ISCA, 2022: 4521-4525. DOI: 10.21437/Interspeech.2022-439.

[16] HUANG WC, COOPER E, TODA T. MOS-Bench: Benchmarking Generalization Abilities of Subjective Speech Quality Assessment Models[J]. IEEE Transactions on Audio, Speech and Language Processing, 2026, 34: 2385-2397. DOI: 10.1109/taslpro.2026.3685883.

[17] HOQ E, GUPTA N, OMONDI D, et al. FUSE-MOS: Fusion of speech embeddings for MOS prediction with uncertainty quantification[C]//Interspeech 2025. [S. l.]: ISCA, 2025: 2350-2354. DOI: 10.21437/Interspeech.2025-2532.

[18] 费涛, 艾山·吾买尔, 杜文旭, 等. 基于 Squeezeformer 的多颗粒度多方面发音质量评测方法[J]. 计算机工程, 2025, 51(1): 81-87. DOI: 10.19678/j.issn.1000-3428.0068594. FEI T, AISHAN W, DU W, et al. Multi-granularity and multi-aspect pronunciation quality evaluation method based on Squeezeformer[J]. Computer Engineering, 2025, 51(1): 81-87.

[19] 王超, 姚姗姗. 基于语音质量自适应和类三元组思想的说话人确认方法[J]. 计算机应用, 2024, 44(12): 3899-3906. DOI: 10.11772/j.issn.1001-9081.2023121857. WANG C, YAO S. Speaker verification method based on speech quality adaptation and triplet-like idea[J]. Journal of Computer Applications, 2024, 44(12): 3899-3906.

[20] ITU-T. Transmission impairments due to speech processing: ITU-T G.113 (09/2024)[S]. Geneva: International Telecommunication Union, 2024.

[21] ITU-T. Wideband E-model: ITU-T G.107.1 (06/2019)[S]. Geneva: International Telecommunication Union, 2019.

[22] FRIEDMAN JH. Greedy function approximation: A gradient boosting machine.[J]. The Annals of Statistics, 2001, 29(5): 1189-1232. DOI: 10.1214/aos/1013203451.

[23] HOWARD A G, ZHU M, CHEN B, et al. MobileNets: Efficient convolutional neural networks for mobile vision applications[EB/OL]. (2017-04-17)[2026-10-11]. https://arxiv.org/abs/1704.04861.

[24] CHO K, VAN MERRIENBOER B, GULCEHRE C, et al. Learning phrase representations using RNN encoder–decoder for statistical machine translation[C]//EMNLP 2014. Doha: Association for Computational Linguistics, 2014: 1724-1734. DOI: 10.3115/v1/D14-1179.

[25] LOSHCHILOV I, HUTTER F. Decoupled weight decay regularization[EB/OL]. (2017-11-14)[2026-10-11]. https://arxiv.org/abs/1711.05101.

[26] HINTON G, VINYALS O, DEAN J. Distilling the knowledge in a neural network[EB/OL]. (2015-03-09)[2026-10-11]. https://arxiv.org/abs/1503.02531.

[27] RONG X, SUN T, ZHANG X, et al. GTCRN: A Speech Enhancement Model Requiring Ultralow Computational Resources[C]//ICASSP 2024 - 2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). [S. l.]: IEEE, 2024: 971-975. DOI: 10.1109/icassp48485.2024.10448310.

[28] 更藏措毛, 黄鹤鸣. 基于多视角注意力的异构双分支解码单通道语音增强[J]. 计算机应用, 2025, 45(10): 3284-3293. DOI: 10.11772/j.issn.1001-9081.2024101463. GENGZANGCUOMAO, HUANG H. Monaural speech enhancement with heterogeneous dual-branch decoding based on multi-view attention[J]. Journal of Computer Applications, 2025, 45(10): 3284-3293.

[29] MAUCH M, DIXON S. pYIN: A fundamental frequency estimator using probabilistic threshold distributions[C]//ICASSP 2014. [S. l.]: IEEE, 2014. DOI: 10.1109/ICASSP.2014.6853678.

[30] ITU-T. Methods, metrics and procedures for statistical evaluation, qualification and comparison of objective quality prediction models: ITU-T P.1401 (01/2020)[S]. Geneva: International Telecommunication Union, 2020.